

1 方法：aGPD-Lite++ 初始化预致密化

1.1 动机

基于 3DGS 的重建在初始化阶段往往存在空间分布不均的问题：稀疏区域（如弱纹理、遮挡后方、视角覆盖不足区域）会导致高斯中心在局部呈现较大间距，从而在训练早期出现“空洞”与结构缺失。为缓解这一问题，预致密化（pre-densification）通常通过在局部邻域插入新点来提升采样密度。然而，朴素的插点策略容易引入两类退化：(1) 由于 kNN 长边可能跨越遮挡边界或跨表面连接，插点可能落在错误的几何位置；(2) 若缺乏可靠深度约束，新点易出现漂浮/穿透，使训练早期受到不透明度与尺度的负面影响。因此，我们希望在**不显著增加计算与实现复杂度、不引入新的可调超参**的前提下，实现一种更稳健的初始化预致密化。

1.2 方法概述

我们提出 aGPD-Lite++，其核心思想是：在稀疏区域触发增密并生成候选点，然后借助 DPT 预测深度提供的多视图一致性约束进行过滤与几何校正，最后对新增高斯采用可信度门控初始化，以降低误新增对训练的干扰。具体流程包括：(1) 用归一化邻域稀疏度 D_{bi} 超阈值触发增密；(2) 在 kNN 图的过长边上进行**极简插值**（每触发点最多插 1 个候选点）；(3) 将 DPT 相对深度通过每视角仿射变换对齐到相机深度尺度；(4) 在候选点两端点的可见交集 $V_i \cap V_j$ 上进行多视图深度一致性计数过滤；(5) 对通过过滤的点执行一次深度回投影校正，使其贴合预测表面；(6) 利用多视图通过次数与残差构造可信度，对新增高斯的不透明度与尺度进行门控初始化。

1.3 为何在“仅可见集合 V_i + 相对深度”设定下需要三项改进

在我们的设定中， V_i 仅表示可见性通过，不包含深度一致性信息；同时 DPT 提供的是相对深度，存在尺度与偏移不确定性。若直接将其用于硬阈值过滤，会出现以下风险：(1) 长边跨表面产生的候选点数量大，过滤压力上升，并提高误通过概率；(2) 过滤通过只能说明“一致性尚可”，但候选点仍可能偏离真实表面；(3) 低可信度候选点即使少量误通过，也可能在早期以较大不透明度/尺度产生不利遮挡效应。

因此，我们引入三项无需新增超参的完善：

(i) 可见交集约束选边: 减少跨遮挡/跨表面候选 当 kNN 图中存在跨遮挡或跨表面连接时, 最长边往往对应错误几何结构。我们在选边时优先要求 $|V_i \cap V_j| \geq 1$, 即两端点至少有一个共同可见视角。该规则仅基于已有可见集合 V_i , 无需额外参数, 但能从源头显著减少“无意义候选”。

(ii) 深度回投影校正: 从“过滤”升级为“过滤 + 几何纠偏” 多视图一致性计数本质上是判别式约束: 它能抑制明显错误, 但不保证候选点落在表面。我们在通过过滤后, 选择残差最小的视角进行深度回投影, 将候选点“拉回”到对齐后的 DPT 预测表面。该校正仅需要一次反投影与坐标变换, 开销极低, 却能明显降低漂浮点残留。

(iii) 可信度门控初始化: 用现成信息抑制低可信度新增的负面影响 我们不引入额外超参, 而是复用过滤过程的计数(通过比例)与残差(相对阈值)构造 q_{new} , 并据此门控新高斯的不透明度与尺度。直观上, 低可信度新增点即使被保留, 也应以更保守的初始化参与优化, 以减少对早期训练的干扰; 高可信度新增点则接近基础初始化。该策略提升稳定性, 同时保留增密收益。

1.4 讨论与局限

相对深度对齐的必要性与稳健性. DPT 提供相对深度, 若不对齐则无法与相机深度比较。我们采用每视角 2 参数仿射对齐(分位数两点法), 避免引入迭代优化与额外超参, 且对尺度/偏移不确定性具有良好适应性。该对齐依赖于每视角存在一定数量的可见高斯样本; 在极端稀疏或视角样本不足时, 可通过跨视角共享统计或增加采样上限缓解(不必作为超参暴露)。

可见集合仅为可见性时的适用性. 由于 V_i 不包含深度一致性信息, 我们将“深度一致”完全交由对齐后的 MV 过滤完成, 并仅用 $V_i \cap V_j$ 缩小检查集合。该设计与工程实现兼容性高, 不需要修改可见性计算模块。

失败模式. 当 DPT 深度在纹理缺失、镜面/透明物体、强遮挡边界处误差较大时, 可能影响过滤与回投影校正的可靠性。我们通过残差自适应阈值与门控初始化降低此类误差的负面影响; 同时, 后续训练阶段的优化仍可逐步修正局部误差。

1.5 超参建议 (可写死以减少调参)

为避免额外调参, 推荐将以下量固定为策略或常数:

$$\begin{aligned} K &= 16, \quad \tau_s = Q(D_b, 0.7), \quad dt = Q(D, 0.6), \quad M = 2, \\ \eta_o &= Q(e, 0.9), \quad \gamma_o = 0.3, \quad \delta = 1.5, \\ q_\ell &= 0.1, \quad q_h = 0.9. \end{aligned}$$

其中 $Q(\cdot, \cdot)$ 为分位数算子, e 为对齐残差样本集合 (跨视角汇总)。

算法 1 aGPD-Lite++: 邻域稀疏度引导的高斯预致密化

输入: 初始高斯 $G = \{G_i\}_{i=1}^N$; 相机集合 C 与投影/深度函数 (π_c, z_c) ; DPT 相对深度图 $\{d_{\text{DPT}}^c\}_{c \in C}$; 可见集合 $\{V_i\}_{i=1}^N$; 常数/超参: $K, \tau_s, dt, M, \eta_o, q_\ell, q_h, \gamma_o, \delta$ 。

输出: 增密后的高斯集合 G 。

A. DPT 深度对齐 (每视角, 分位数两点法)

对每个 $c \in C$:

采样 $\mathcal{S}_c = \{i \mid c \in V_i, \pi_c(\mu_i) \in \Omega_c\}$ 中若干 i ;

记 $z_i = z_c(\mu_i)$, $d_i = d_{\text{DPT}}^c(\pi_c(\mu_i))$;

若 $\text{Corr}(\{z_i\}, \{d_i\}) < 0$, 则令 $d_i \leftarrow -d_i$ (避免符号相反的极端情况);

取分位数: $z_\ell = Q(\{z_i\}, q_\ell)$, $z_h = Q(\{z_i\}, q_h)$; $d_\ell = Q(\{d_i\}, q_\ell)$, $d_h = Q(\{d_i\}, q_h)$;

$a_c \leftarrow (z_h - z_\ell) / (d_h - d_\ell)$, $b_c \leftarrow z_\ell - a_c d_\ell$;

定义 $z_{\text{render}}^c(p) = a_c d_{\text{DPT}}^c(p) + b_c$ 。

B. kNN 图与稀疏触发

对每个 $i = 1, \dots, N$: 求 $N_K(i)$, 计算 D_i, D_{bi} 。

令 $\mathcal{T} \leftarrow \{i \mid D_{bi} > \tau_s\}$ 。

C. 候选生成 (可见交集约束选边 + 中点插值, 每点至多 1 个)

初始化 $\mathcal{P} \leftarrow \emptyset$ 。

对每个 $i \in \mathcal{T}$:

若存在 $j \in N_K(i)$ 使得 $|V_i \cap V_j| \geq 1$,

令 $j \leftarrow \arg \max_{u \in N_K(i), |V_i \cap V_u| \geq 1} \|\mu_i - \mu_u\|_2$;

否则令 $j \leftarrow \arg \max_{u \in N_K(i)} \|\mu_i - \mu_u\|_2$;

若 $\|\mu_i - \mu_j\|_2 > 2dt$, 则

$\mu_{\text{new}}^{(0)} \leftarrow \frac{1}{2}(\mu_i + \mu_j)$, 并将 $(\mu_{\text{new}}^{(0)}, i, j)$ 加入 $\mathcal{P}$ 。

D. 多视图深度一致性过滤 (在 $V_i \cap V_j$ 上计数, 抽样 + 早停)

初始化 $\mathcal{A} \leftarrow \emptyset$ 。

对每个 $(\mu_{\text{new}}^{(0)}, i, j) \in \mathcal{P}$:

令 $V_{ij} \leftarrow V_i \cap V_j$; 从 V_{ij} 中抽样少量视角组成 $\mathcal{C}_{\text{check}}$ (常数个, 可 early-exit)。

初始化 $\text{cnt} \leftarrow 0$, $\mathcal{C}_{\text{pass}} \leftarrow \emptyset$, $\mathcal{E} \leftarrow \emptyset$ 。

对每个 $c \in \mathcal{C}_{\text{check}}$:

$p \leftarrow \pi_c(\mu_{\text{new}}^{(0)})$; 若 $p \in \Omega_c$,

计算 $e \leftarrow |z_c(\mu_{\text{new}}^{(0)}) - z_{\text{render}}^c(p)|$;

若 $e < \eta_o$, 则 $\text{cnt} \leftarrow \text{cnt} + 1$, $\mathcal{C}_{\text{pass}} \leftarrow \mathcal{C}_{\text{pass}} \cup \{c\}$, $\mathcal{E} \leftarrow \mathcal{E} \cup \{e\}$;

若 $\text{cnt} \geq M$ 则停止检查 (early-exit)。

若 $\text{cnt} \geq M$, 则将 $(\mu_{\text{new}}^{(0)}, i, j, \mathcal{C}_{\text{pass}}, \mathcal{C}_{\text{check}}, \mathcal{E})$ 加入 $\mathcal{A}$ 。

E. 深度回投影校正 (Refine) + F. 可信度门控初始化

对每个 $(\mu_{\text{new}}^{(0)}, i, j, \mathcal{C}_{\text{pass}}, \mathcal{C}_{\text{check}}, \mathcal{E}) \in \mathcal{A}$:

$c \leftarrow \arg \min_{c \in \mathcal{C}_{\text{pass}}} |z_c(\mu_{\text{new}}^{(0)}) - z_{\text{render}}^c(\pi_c(\mu_{\text{new}}^{(0)}))|$;

$p \leftarrow \pi_{c(\mu_{\text{new}}^{(0)})}$;

$\mu_{\text{new}} \leftarrow \text{Unproject}(c^{p, z_{\text{render}}^c(p)})$;

$q_{\text{new}} \leftarrow \text{clip}\left(\frac{\text{cnt}}{\max(1, |\mathcal{C}_{\text{check}}|)}, 0, 1\right) \cdot \max\left(0, 1 - \frac{\text{median}(\mathcal{E})}{\eta_o}\right)$;

构造 G_{new} :

$\mu \leftarrow \mu_{\text{new}}$, $R \leftarrow R_i$, $f \leftarrow \frac{1}{2}(f_i + f_j)$,

$o \leftarrow \gamma_o o_i q_{\text{new}}$, $s \leftarrow (s_i / \delta) \cdot (0.5 + 0.5 q_{\text{new}})$;

$G \leftarrow G \cup \{G_{\text{new}}\}$ 。

返回: G 。

2 复杂度分析

设高斯数为 N 、相机数为 $|C|$, 每个点的近邻数为 K (常数), 每个候选点在过滤时抽样检查的视角数为 S (常数, 且 $S \geq M$)。设每个视角用于对齐的样本数为 $|S_c|$ (可下采样为常数或与 N 成比例子集)。

(1) DPT 对齐. 对每个视角 c , 计算样本对 (z_i, d_i) 并做分位数统计, 时间为 $O(|\mathcal{S}_c|)$ 。总计为

$$O\left(\sum_{c \in C} |\mathcal{S}_c|\right),$$

若每视角采样固定数量, 则为 $O(|C|)$ 。

(2) kNN 与稀疏触发. kNN 构建视实现而定: 基于 KD-tree/FAISS 通常为 $O(N \log N)$ 到近似线性。在得到 $N_K(i)$ 后, 计算 D_i 为 $O(NK) = O(N)$ (K 为常数)。

(3) 候选生成 (极简每触发点最多 1 个). 触发点数为 $|\mathcal{T}| \leq N$ 。每个触发点选边需要遍历 K 个邻居并做集合交集非空判断, 记交集判断为 $O(1)$ (例如布尔标记/bitset 或哈希集合短路)。故该步为 $O(|\mathcal{T}|K) = O(N)$ 。

(4) MV 深度一致性过滤与回投影校正. 候选数为 $|\mathcal{P}| \leq |\mathcal{T}|$ (极简版每触发点至多 1 个候选)。每个候选仅检查 S 个视角并 early-exit, 因此过滤为 $O(|\mathcal{P}|S) = O(N)$ (S 为常数)。通过点的回投影校正与门控初始化为常数开销。

总体复杂度. 总体时间复杂度由 kNN 构建与对齐采样主导, 过滤与新增为线性/常数级:

$$O\left(\text{kNN}(N) + \sum_{c \in C} |\mathcal{S}_c| + N\right).$$

空间复杂度主要为存储高斯参数、kNN 索引、深度图与少量对齐参数 (a_c, b_c) , 约为

$$O(N + |C| + \text{depth maps}).$$